
## Домашнее задание к 3 уроку

## 1. Какая связь между DataFrame и Dataset?


В Catalist генерируется байт код


## Comparisons among DataFrame, Dataset, and RDD


 DataFrame (with relational operations) and Dataset (with lambda functions) use Catalyst and row-oriented data representation on off-heap




2. Соберите WordCount приложение, запустите на датасете ppkm\_sentiment







- 3. \* Измените WordCount так, чтобы он удалял знаки препинания и приводил все слова к единому регистру
- 4. \* Добавьте в WordCount возможность через конфигурацию задать список стоп-слов, которые будут отфильтрованы во время работы приложения
- 5. Измените выход WordCount так, чтобы сортировка была по количеству повторений, а список слов был во втором столбце, а не в первом





6. \* Почему в примере в выходном файле получилось 200 партиций? В конфигураторе SparkSession по умолчанию установленно - 200 партиций